

Рассмотрим зависимые X и Y .

Представим Y как функцию X в виде

$$Y \approx g(X) = \beta X + \alpha, \text{ где}$$

α, β – параметры, подлежащие определению.

Функция $Y = g(X)$ – *среднеквадратическая регрессия* Y на X .

Теорема 3 (уравнение среднеквадратической регрессии)

$$Y - m_Y = r_{XY} \frac{\sigma_Y}{\sigma_X} (X - m_X)$$

— уравнение
регрессии
Y на X;

$$X - m_X = r_{XY} \frac{\sigma_X}{\sigma_Y} (Y - m_Y)$$

— уравнение
регрессии
X на Y.

Доказательство

Рассмотрим вспомогательную функцию:

$$F(\alpha, \beta) = M \left[(Y - \alpha - \beta X)^2 \right]$$

Цель: $F(\alpha, \beta) \rightarrow \min.$

$$F(\alpha, \beta) = M \left[(Y - \alpha - \beta X + m_Y - m_Y + \beta m_X - \beta m_X)^2 \right] =$$

$$= M \left[((Y - m_Y) + m_Y - \alpha - \beta(X - m_X) - \beta m_X)^2 \right] =$$

$$= M \left[\left((Y - m_Y) - \beta (X - m_X) + (m_Y - \alpha - \beta m_X) \right)^2 \right] =$$

= [возводим сумму в квадрат; при этом

$$M[X - m_X] = M[Y - m_Y] = 0;$$

$$M[(X - m_X)(Y - m_Y)] =$$

$$\begin{aligned}
 &= M \left[(Y - m_Y)^2 + \beta^2 (X - m_X)^2 + (m_Y - \alpha - \beta m_X)^2 + \right. \\
 &\quad + 2(Y - m_Y)(m_Y - \alpha - \beta m_X) - 2(Y - m_Y) \cdot \beta \cdot (X - m_X) - \\
 &\quad \left. - 2\beta \cdot (X - m_X)(m_Y - \alpha - \beta m_X) \right] = \\
 &= M \left[(Y - m_Y)^2 \right] + \beta^2 \cdot M \left[(X - m_X)^2 \right] + (m_Y - \alpha - \beta m_X)^2 + \\
 &\quad + 2M \left[Y - m_Y \right] \cdot (m_Y - \alpha - \beta m_X) - 2\beta \cdot M \left[(Y - m_Y)(X - m_X) \right] -
 \end{aligned}$$

$$\begin{aligned} &= D[Y] + \beta^2 D[X] + (m_Y - \alpha - \beta m_X)^2 - \\ &- 2\beta \cdot M[(Y - m_Y)(X - m_X)] = \sigma_Y^2 + \beta^2 \sigma_X^2 + \\ &+ (m_Y - \alpha - \beta m_X)^2 - 2\beta r_{XY} \sigma_X \sigma_Y. \end{aligned}$$

Исследуем $F(\alpha, \beta)$ на экстремум:

$$\begin{cases} \frac{\partial F}{\partial \alpha} = -2(m_Y - \alpha - \beta m_X) = 0 \\ \frac{\partial F}{\partial \beta} = 2\beta \sigma_X^2 + 2(m_Y - \alpha - \beta m_X)(-m_X) - 2r_{XY}\sigma_X\sigma_Y = 0. \end{cases}$$

Решая систему, получаем: $\beta = r_{XY} \frac{\sigma_Y}{\sigma_X};$

$$\alpha = m_Y - r_{XY} \frac{\sigma_Y}{\sigma_X} m_X.$$

Легко проверить, что при найденных α и β функция $F(\alpha, \beta)$ имеет минимум. Подставляя в уравнение $Y = \beta X + \alpha$ найденные параметры, получаем требуемое.

Пример задачи на линейную корреляцию СВ

Известен закон распределения случайного вектора

Y/X	25	30	35
120	0,05		
125	0,15	0,3	0,05
130	0,05	0,25	0,1
135			0,05

- 1) Найти законы распределения составляющих. Вычислить числовые характеристики X и Y .
- 2) Записать условные законы распределения $Y|X$ и $X|Y$. Построить на координатной плоскости эмпирические линии регрессии.
- 3) Вычислить коэффициент корреляции r_{XY} .
- 4) Записать уравнения теоретических линий регрессии Y по X и X по Y .
Построить теоретические линии регрессии.

Решение.

1)

Y/X	25	30	35	$\Sigma \rightarrow$
120	0,05			0,05
125	0,15	0,3	0,05	0,5
130	0,05	0,25	0,1	0,4
135			0,05	0,05
$\Sigma \downarrow$	0,25	0,55	0,2	1

X	25	30	35
P	0,25	0,55	0,2

Y	120	125	130	135
P	0,05	0,5	0,4	0,05

Закон распределения X и Y .

Числові характеристики:

$$M[X] = 29,75$$

$$D[X] = 11,2$$

$$\sigma[X] = 3,34$$

$$M[Y] = 127,25$$

$$D[Y] = 11,2$$

$$\sigma[Y] = 3,34$$

Скласти умовні закони розподілення.

$Y X=25$	120	125	130
P	$0,2=0,05/0,25$	$0,6=0,15/0,25$	$0,2=0,05/0,25$

$M[Y|X=25] = 125$ — условное м.о.

$A_1(25; 125)$

$Y X=30$	125	130
P	0,54	0,46

$M[Y|X=30] = 127,3$

$A_2(30; 127,3)$

$Y X=35$	125	130	135
P	0,25	0,5	0,25

$$A_3 (35; 130)$$

$$\parallel$$

$$M[Y|X=35]$$

$A_1 A_2 A_3$ — эмпирическая логаная Y по X .

Аналогично находим $B_1 B_2 B_3 B_4$ — эмпирическую логаную
 X по Y :

$$B_1 (25; 120); B_2 (29; 125); B_3 (30, 625; 130); B_4 (35; 135)$$

$$\parallel \quad \parallel$$

$$M[X|Y=125] \quad M[X|Y=135]$$

Вычисление коэффициента корреляции.

Переходим к системе центрированных СВ $(X - M[X], Y - M[Y])$.

$\begin{matrix} x-m_x \\ y-m_y \end{matrix}$	-4,75	0,25	5,25
-7,75	0,05		
-2,75	0,15	0,3	0,05
2,25	0,05	0,25	0,1
7,75			0,05

$$r_{XY} = \frac{K_{XY}}{\sigma_X \sigma_Y}$$

$$K_{XY} = \sum_{i=1}^n \sum_{j=1}^m (x_i - m_X) \cdot (y_j - m_Y) \cdot p_{ij}$$

$$K_{XY} = 5,69$$

$$r_{XY} = \frac{5,69}{11,2} = 0,51$$

Уравнения линий регрессии.


$$Y - 127,25 = 0,51 \cdot \frac{3,34}{3,34} (X - 29,75)$$

$Y = 0,51 X + 112,1$ — теоретическая линия регрессии Y по X


$$X - 29,75 = 0,51 \cdot \frac{3,34}{3,34} (Y - 127,25)$$

$$X = 0,51 Y - 35,14$$

Построение эмпирических ломаных и теоретических линий регрессии.



n-мерные случайные величины



Определение

n-мерной случайной величиной называется совокупность *n* измеримых функций

$$(\xi_1(\omega), \xi_2(\omega), \xi_3(\omega), \dots, \xi_n(\omega)),$$

отображающих

$$(\Omega, \mathcal{A}) \rightarrow (R^n, \mathcal{B}), \text{ где}$$

\mathcal{B} – борелевская σ -алгебра в R^n .

Необходимым и достаточным условием измеримости системы функций является условие:

$$\forall x_1, x_2, \dots, x_n \quad \{\omega: \xi_1(\omega) < x_1, \xi_2(\omega) < x_2, \dots, \xi_n(\omega) < x_n\} \in \mathcal{A}.$$

Поэтому основной характеристикой n -мерной СВ $\xi = (\xi_1, \xi_2, \dots, \xi_n)$ является функция распределения

$$F(x_1, x_2, \dots, x_n) = P(\xi_1 < x_1, \xi_2 < x_2, \dots, \xi_n < x_n).$$

Свойства функции распределения аналогичны свойствам функции распределения одномерной СВ.

Свойства функции распределения $F(x_1, x_2, \dots, x_n)$

- $F(x_1, x_2, \dots, x_n)$ – неубывающая функция по каждому из своих аргументов
- $\lim_{x_i \rightarrow -\infty} F(x_1, x_2, \dots, x_n) = 0, \forall i \in \overline{1, n}, \quad \lim_{x_1, x_2, \dots, x_n \rightarrow +\infty} F(x_1, x_2, \dots, x_n) = 1$

В этом случае функцию распределения можно представить в виде

$$F(x_1, x_2, \dots, x_n) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \dots \int_{-\infty}^{x_n} f(t_1, t_2, \dots, t_n) dt_1 dt_2 \dots dt_n,$$

где почти всюду выполняется равенство

$$f(x_1, x_2, \dots, x_n) = \frac{\partial^n F(x_1, x_2, \dots, x_n)}{\partial x_1 \partial x_2 \dots \partial x_n}.$$

Свойства плотности вероятности $f(x_1, x_2, \dots, x_n)$

случайного вектора $\xi = (\xi_1, \xi_2, \dots, \xi_n)$.

- Неотрицательность: $f(x_1, x_2, \dots, x_n) \geq 0$.

- Условие нормированности:

$$\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n = 1$$

- Если $A \in \mathcal{B}$, то $P(\xi \in D) = \int \int \dots \int_D f(x_1, x_2, \dots, x_n) dx_1 dx_2 \dots dx_n$.

Независимость n случайных величин

СВ $\xi_1, \xi_2, \dots, \xi_n$ **независимы в совокупности**, если события $\xi_1 < x_1, \xi_2 < x_2, \dots, \xi_n < x_n$ независимы в совокупности для любых $x_1, x_2, \dots, x_n \in \mathbb{R}$.

СВ $\xi_1, \xi_2, \dots, \xi_n$ **независимы в совокупности**, если для любого набора борелевских подмножеств $B_1, B_2, \dots, B_n \in \mathcal{B}(\mathbb{R})$ имеет место равенство

$$P(\xi_1 \in B_1, \xi_2 \in B_2, \dots, \xi_n \in B_n) = P(\xi_1 \in B_1)P(\xi_2 \in B_2) \cdots P(\xi_n \in B_n).$$

$(\xi_1, \xi_2, \dots, \xi_n \text{ независимы в совокупности}) \Leftrightarrow$
 $\Leftrightarrow (F(x_1, x_2, \dots, x_n) = F_1(x_1)F_2(x_2) \dots F_n(x_n))$

$(\xi_1, \xi_2, \dots, \xi_n \text{ непрерывны, независимы}$
 $\text{в совокупности}) \Leftrightarrow (f(x_1, x_2, \dots, x_n) = f_1(x_1)f_2(x_2) \dots f_n(x_n))$

Плотность распределения определяется с точностью до её значений на множестве нулевой меры Лебега, а значит последнее равенство понимается как «почти всюду».